12. Juli 2015

Aufgabenblatt 3

Gruppe 05

Dora Szücs – 358573 – BA Informatik
Sarah Köhler – 356394 – BA Informatik
Christina Pavlidis – 356230 – BA Economics
Daniela Andrzejewska – 356254 – BA Economics
Charlotte Rochell – 348926 – BA Economics

Tutorium 3: Mittwoch 10 – 12, H3008
Tutor: Marius

Aufgabe 2: OLAP und OLTP

1. OLTP: Es werden viele transaktionale Updates gemacht, wenn Gutscheine als eingelöst markiert werden, etc.
2. OLAP: Vergleich der Gutscheineinlösungszahlungen der Abteilungen und der wöchentlicher Vergleich der Verkäufer nach Gutscheinverkäufen
3. OLTP: viele transaktionale Updates um die Kundeninfos in das System einzutragen
4. OLAP: Analyse der Kundendaten und Verkaufszahlen um eine ideale Marketingstrategie zu entwickeln

Aufgabe 3

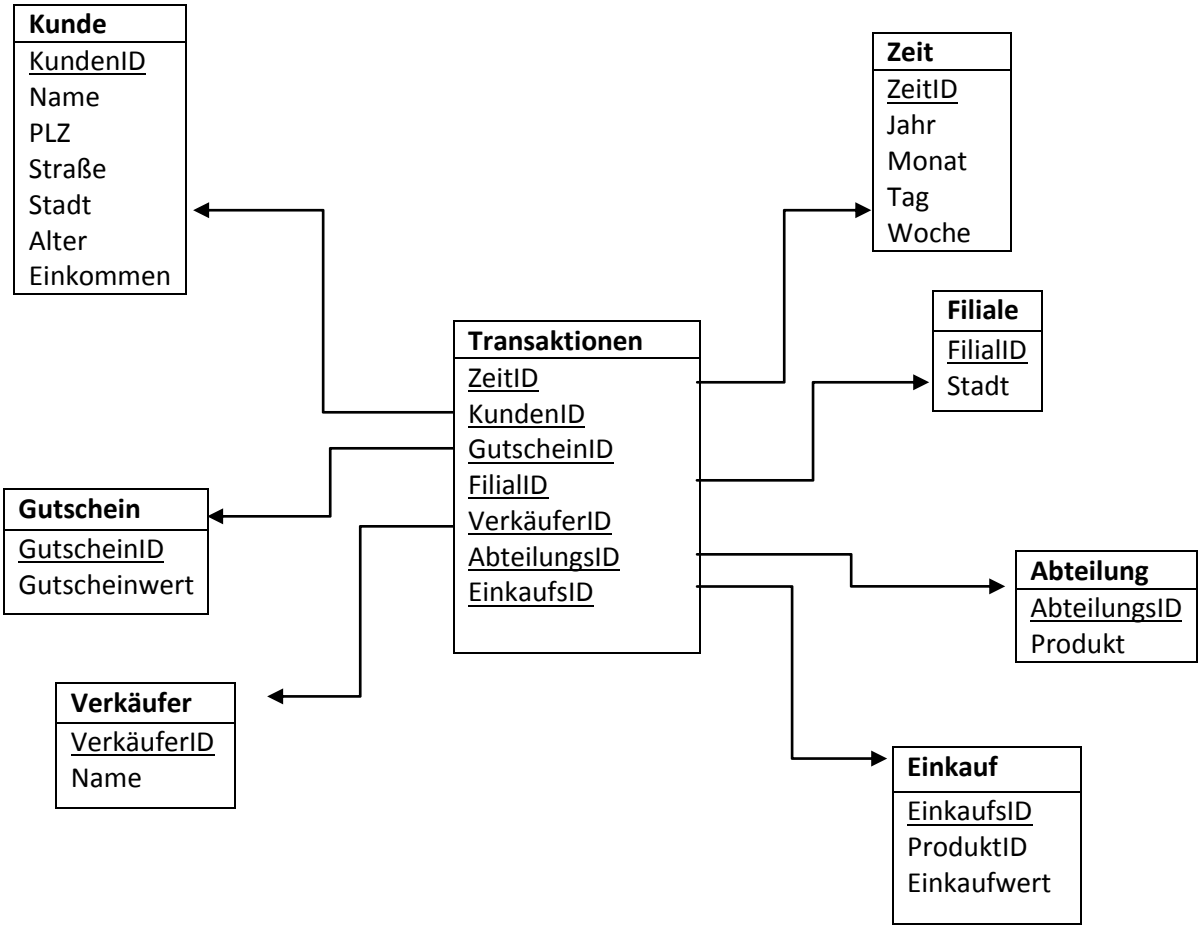
Kunde
KundenID
Name
PLZ
Straße
Stadt
Alter
Einkommen
Zeit
ZeitID
Jahr
Monat
Tag
Woche
Filiale
FilialID
Stadt
Transaktionen
ZeitID
KundenID
GutscheinID
FilialID
VerkäuferID
AbteilungsID
EinkaufsID
Gutschein
GutscheinID
Gutscheinwert
Abteilung
AbteilungsID
Produkt
Verkäufer
VerkäuferID
Name
Einkauf
EinkaufsID
ProduktID
Einkaufwert

Aufagbe 5

ID	quantitativ, diskret	Zahlen oder Größenwerte; Nur ganze Werte angenommen werden
Alter	quantitativ, diskret	Zahlen oder Größenwerte; Nur ganze Werte angenommen werden
Nationalität	qualitativ, nominal	Namen oder Eigenschaften; Reine qualitative Merkmalsausprägung ohne natürliche Ordnung
Verheiratet?	qualitativ, binär	Namen oder Eigenschaften; Dummy-Variable mit Ausprägungen 0 oder 1 (hier ja oder nein)
Anzahl der Kinder	quantitativ, diskret	Zahlen oder Größenwerte; Nur ganze Werte angenommen werden
Beruf	qualitativ, nominal	Namen oder Eigenschaften; Reine qualitative Merkmalsausprägung ohne natürliche Ordnung
Einkommen	qualitativ, ordinal	Namen oder Eigenschaften; Ausdruck einer Rangfolge (hier Einkommen)
Credit Score	quantitativ, kontinuierlich	Zahlen oder Größenwerte; Zahlen mit Nachkommastellen (jede beliebige Wert aus der Menge der reellen Zahlen)

Aufgabe 7

Import der Bibliotheken & Quelldaten

In [2]:

```
# Standard Python Math Bibliothek.
import math
# Lädt Matplotlib, eine Bibliothek zum Estellen von Plots & Diagrammen.
import matplotlib.pyplot as plt
# Matplotlib Plots sollen direkt im Notebook erscheinen.
%matplotlib inline
# Lädt NumPy, eine Bibliothek zur numerischen Analyse.
import numpy as np
np.random.seed(102)
# Lädt Pandas, eine Bibliothek zur Analyse von strukturierten Daten.
import pandas as pd
```

In [38]:

```
housing_df = pd.read_csv("housing.csv", sep=';', index_col=False)
print "Housing:\n", housing_df.dtypes
```

```
Housing:
crim       float64
zn         float64
indus      float64
chas         int64
nox        float64
rm         float64
age        float64
dis        float64
rad        float64
tax        float64
ptratio    float64
b          float64
lstat      float64
medv       float64
dtype: object
```

1. Basisstatistiken der Stickstoffkonzentration:

In [12]:

```
max_nox = housing_df.nox.max()
print "Maximum: ", max_nox
min_nox = housing_df.nox.min()
print "Minimum: ", min_nox
mean_nox = housing_df.nox.mean()
print "Mittelwert: ", mean_nox
median_nox = housing_df.nox.median()
print "Median: ", median_nox
stderr_nox = np.sqrt(housing_df.nox.var())
print "Standardabweichung: ", stderr_nox
```

```
Maximum:  0.871
Minimum:  0.385
Mittelwert:  0.554695059289
Median:  0.538
Standardabweichung:  0.115877675668
```

2. Stickstoffkonzentration und Kriminalität

In [21]:

```
avg_crim_over = housing_df[housing_df.nox > 0.53].crim.mean()
avg_crim_below = housing_df[housing_df.nox <= 0.53].crim.mean()

print "Durchschnittliche Kriminalitätsrate für Bezirke über dem Grenzwert:
", avg_crim_over
print "Durchschnittliche Kriminalitätsrate für Bezirke unter dem Grenzwert:
", avg_crim_below
```

```
Durchschnittliche Kriminalitätsrate für Bezirke über dem Grenzw
ert:  6.86128145038
Durchschnittliche Kriminalitätsrate für Bezirke unter dem Grenz
wert:  0.126176967213
```

3. Verhaltensändernde Wirkung der Stickstoffkonzentration

Nein: Korrelation impliziert keinen kausalen Zusammenhang

Es ist ebenso möglich, dass andere Faktoren, die wir nicht untersucht haben für den Zusammenhang verantwortlich sind.

4. Mittlerer Wert von Häusern

In [22]:

```
housing_df.medv.hist()
```

Out[22]:

```
<matplotlib.axes.AxesSubplot at 0x10b9a2210>
```

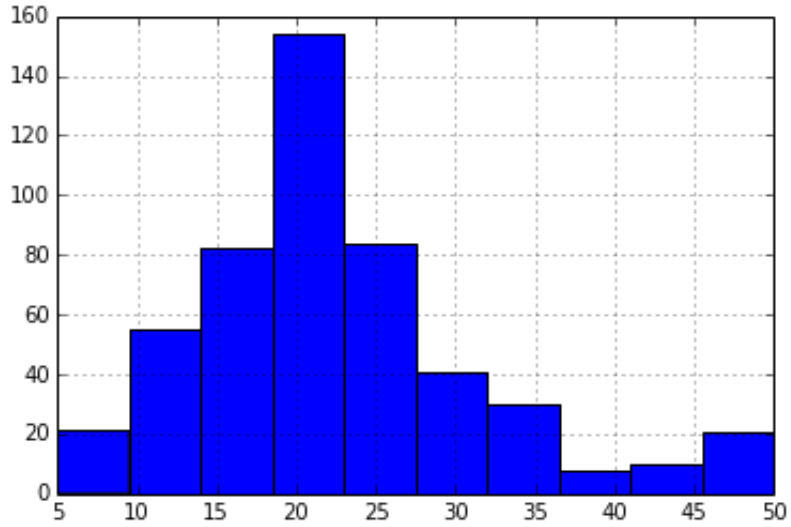

Aus dem Histogramm lassen sich die Häufigkeiten (y-Achse) der verschiedenen Wertbereiche für Häuser (x-Achse) pro Vorort ablesen. Beispielsweise gibt es knapp über 150 Vororte wo der durchschnittliche Wert der Häuser bei knapp über 20000 Dollar liegt. Das Histogramm scheint in etwa eine Normalverteilung abzubilden, allerdings ist auffällig, dass es im Bereich der sehr hohen durchschnittlichen Werte noch einen Aussschlag nach oben gibt.

5. Korrelationskoeffizient des Mittleren Wertes der Häuser

In [39]:

```
korr_crim = np.corrcoef(housing_df.medv, housing_df.crim)[0, 1]
print "Pearson's Korrelationskoeffizient für crim: ", korr_crim
zn_crim = np.corrcoef(housing_df.medv, housing_df.zn)[0, 1]
print "Pearson's Korrelationskoeffizient für zn: ", zn_crim
korr_indus = np.corrcoef(housing_df.medv, housing_df.indus)[0, 1]
print "Pearson's Korrelationskoeffizient für indus: ", korr_indus
korr_chas = np.corrcoef(housing_df.medv, housing_df.chas)[0, 1]
print "Pearson's Korrelationskoeffizient für chas: ", korr_chas
korr_nox = np.corrcoef(housing_df.medv, housing_df.nox)[0, 1]
print "Pearson's Korrelationskoeffizient für nox: ", korr_nox
korr_rm = np.corrcoef(housing_df.medv, housing_df.rm)[0, 1]
print "Pearson's Korrelationskoeffizient für rm: ", korr_rm
korr_age = np.corrcoef(housing_df.medv, housing_df.age)[0, 1]
print "Pearson's Korrelationskoeffizient für age: ", korr_age
korr_dis = np.corrcoef(housing_df.medv, housing_df.dis)[0, 1]
print "Pearson's Korrelationskoeffizient für dis: ", korr_dis
korr_rad = np.corrcoef(housing_df.medv, housing_df.rad)[0, 1]
print "Pearson's Korrelationskoeffizient für rad: ", korr_rad
korr_tax = np.corrcoef(housing_df.medv, housing_df.tax)[0, 1]
print "Pearson's Korrelationskoeffizient für tax: ", korr_tax
korr_ptratio = np.corrcoef(housing_df.medv, housing_df.ptratio)[0, 1]
print "Pearson's Korrelationskoeffizient für ptratio: ", korr_ptratio

korr_b = np.corrcoef(housing_df.medv, housing_df.b)[0, 1]
print "Pearson's Korrelationskoeffizient für b: ", korr_b
korr_lstat = np.corrcoef(housing_df.medv, housing_df.lstat)[0, 1]
print "Pearson's Korrelationskoeffizient für lstat: ", korr_lstat
```

```
Pearson's Korrelationskoeffizient für crim:  -0.388304608587
Pearson's Korrelationskoeffizient für zn:  0.360445342451
Pearson's Korrelationskoeffizient für indus:  -0.483725160028
Pearson's Korrelationskoeffizient für chas:  0.17526017719
Pearson's Korrelationskoeffizient für nox:  -0.427320772373
Pearson's Korrelationskoeffizient für rm:  0.695359947072
Pearson's Korrelationskoeffizient für age:  -0.376954565005
Pearson's Korrelationskoeffizient für dis:  0.249928734086
Pearson's Korrelationskoeffizient für rad:  -0.38162623064
Pearson's Korrelationskoeffizient für tax:  -0.468535933568
Pearson's Korrelationskoeffizient für ptratio:  -0.507786685538
Pearson's Korrelationskoeffizient für b:  0.333460819657
Pearson's Korrelationskoeffizient für lstat:  -0.737662726174
```

6. Scatterplot des Zusammenhangs zwischen MEDV und LSTAT

In [26]:

```
housing_df.plot(kind='scatter', x='lstat', y='medv')
```

Out[26]:

```
<matplotlib.axes.AxesSubplot at 0x10eb60810>
```

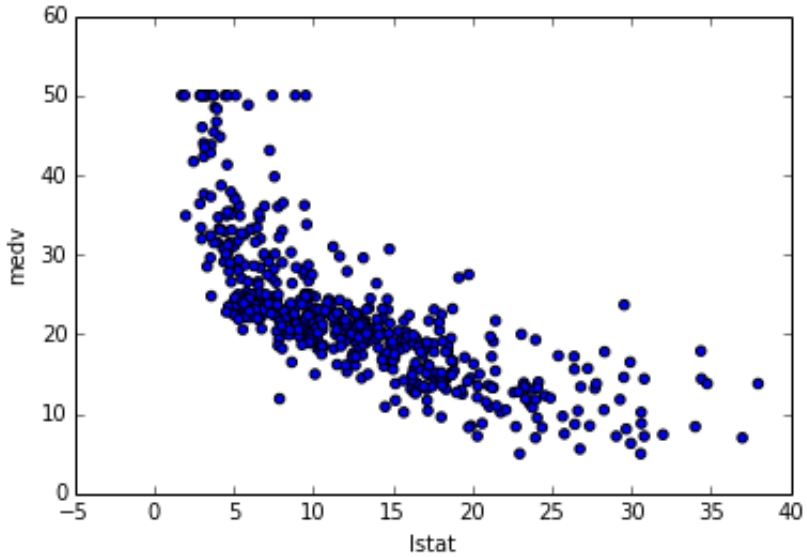

Dass die beiden Parameter negativ korreliert sind, bedeutet, dass in Vororten mit höheren durchschnittlichen Hauspreisen niedrigere Anteile einkommensschwacher Personen leben und umgekehrt.

7. Zusammenhang von Crim, Nox und Lstat

In [40]:

```
housing_nox_over = housing_df[housing_df.nox > 0.53]
housing_nox_over.plot(kind='scatter', x='lstat', y='crim')
housing_nox_below = housing_df[housing_df.nox <= 0.53]
housing_nox_below.plot(kind='scatter', x='lstat', y='crim')

housing_df.plot(kind='scatter', x='nox', y='crim')
housing_df.plot(kind='scatter', x='lstat', y='crim')
korr_lstat_crim= np.corrcoef(housing_df.crim, housing_df.lstat)[0, 1]
korr_nox_crim= np.corrcoef(housing_df.crim, housing_df.nox)[0, 1]
korr_lstat_nox= np.corrcoef(housing_df.nox, housing_df.lstat)[0, 1]
print "Korrelationskoeffizient von Kriminalität und niedrigem Einkommen: ",
korr_lstat_crim
print "Korrelationskoeffizient von Kriminalität und Stickstoffkonzentratio
n", korr_nox_crim
print "Korrelationskoeffizient von niedrigem Einkommen und Stickstoffkonzen
tration", korr_lstat_nox
```

```
Korrelationskoeffizient von Kriminalität und niedrigem Einkomme
n:  0.455621479448
Korrelationskoeffizient von Kriminalität und Stickstoffkonzentr
ation 0.420971711392
Korrelationskoeffizient von niedrigem Einkommen und Stickstoffk

onzentration 0.590878920881
```

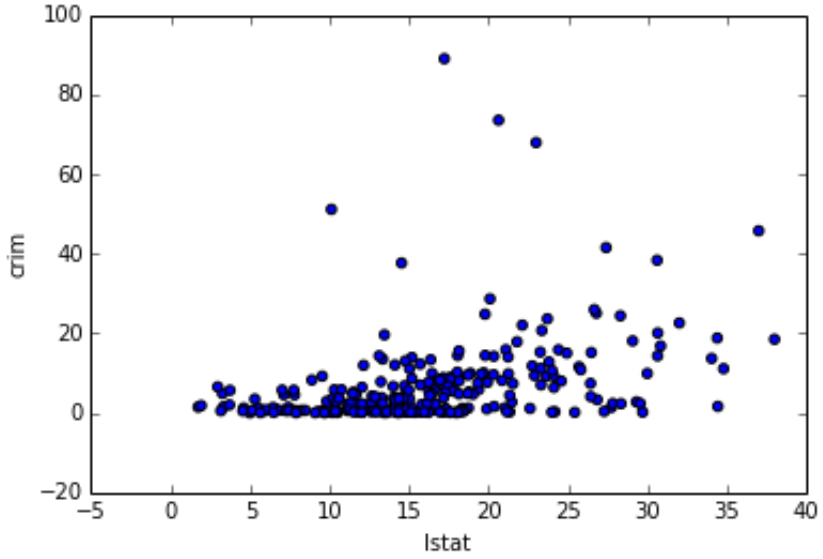

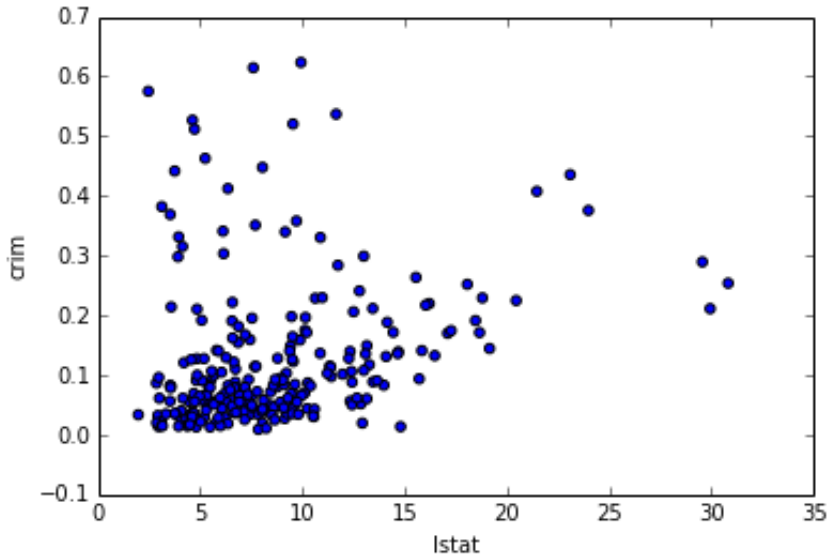

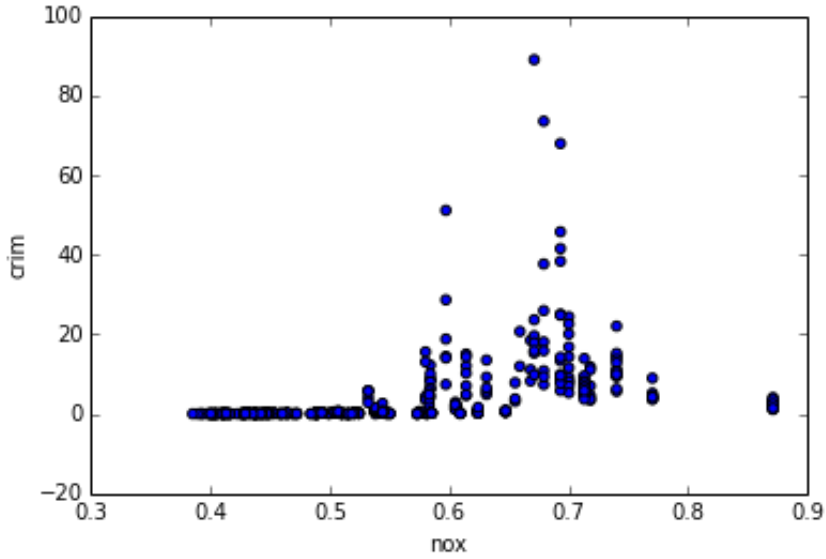

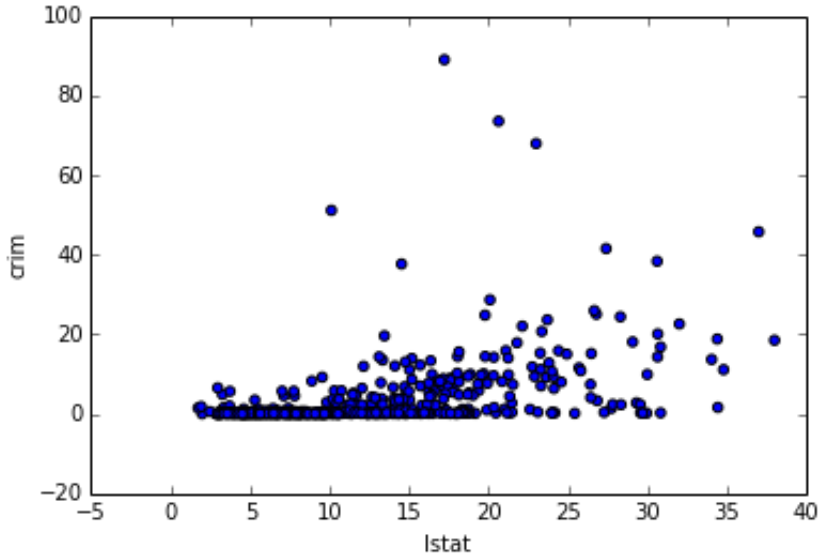

Der letzte Plot zeigt den Zusammenhang zwischen der Kriminalität und dem Anteil der Personen mit niedrigem Einkommen. Die Grafik deutet auf einen leicht positiven Zusammenhang hin, das heißt je mehr Personen mit niedrigem Einkommen in einem Vorort leben, desto höher ist dort die Kriminalität. Dies deckt sich auch eher mit bisherigen Forschungsergebnissen, als ein Zusammenhang mit der Stickstoffkonzentration (wir weiter oben untersucht).

Deswegen ist zu vermuten, dass der kausale Zusammenhang nicht zwischen NOX und CRIM besteht, sondern die Ursache für eine festgestellte Korrelation durch eine oder mehrerer andere Größen bedingt ist. Ein möglicher Zusammenhang wäre etwa über die Lage im Verhältnis zu Industriegebieten: Bezirke nahe einem Industriegebiet haben eine höhere Konzentration an Schadstoffen in der Luft. Zudem wohnen dort eher die Arbeiter aus den Fabriken, welche eher zu den einkommensschwachen Haushalten zählen.