

3. Scheduling

- Überblick
 - 3.1 Einführung
 - 3.2 Schedulingstrategien
 - 3.3 Multilevel-Scheduling
 - 3.4 Scheduling mit Sollzeitpunkten
 - 3.5 Fallstudien Unix und Windows



3.1 Einführung

Jobs haben Eigenschaften: periodisch/einmalig, Dauer bekannt (oder unbekannt), benötigte Ressourcen, unterbrechbar oder nicht, Deadline (hart oder weich), Abhängigkeiten von anderen Jobs

Scheduling (Ablaufplanung)

-> je nach Eigenschaften sind verschiedene Verfahren sinnvoll

- Räumliche und zeitliche Zuordnung von Aktivitäten zu Instanzen, welche diese Aktivitäten durchführen können
- Welcher Prozess soll ausgeführt werden? Auswahl durch
 - Scheduler als Teil der Systemsoftware anhand der
 - ➤ Scheduling-Strategie: Zuordnungsalgorithmus Prozesse → Prozessoren
 - Short-Term-Scheduler: Prozesszuteilung unter bereiten Prozessen, einfache und effizient ausführbare Strategie
 - Long-Term-Scheduler: Längerfristige, komplexe Planung der Ressourcenzuteilung, etwa Speicherauslagerung
- Scheduling wichtig für subjektive Wahrnehmung der Rechnerleistung
 - ➤ P1: Schließen eines Fensters, aktualisieren der Oberfläche (2 sec)
 - P2: Senden einer E-mail (2 sec)
 - Reihenfolge P2P1: Benutzer nimmt die Verzögerung sofort wahr, empfindet den Rechner als langsam
 - Reihenfolge P1P2: Verzögerung des E-mail-Versands um 2 Sekunden bleibt wahrscheinlich unbemerkt
 Folie 3 neu: Zeitskala



CPU 1

CPU₂

CPU 3

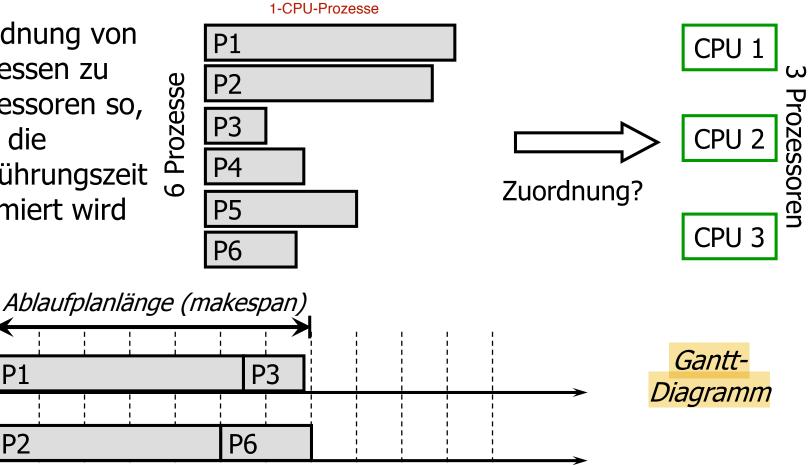
Klassisches Scheduling-Problem

 Zuordnung von Prozessen zu Prozessoren so, dass die Ausführungszeit minimiert wird

P1

P2

P5



Rechenzeit



Gestaltungsparameter für Scheduling

Prozessmenge statisch oder dynamisch?

auch: geschlossenes System, z.B. Embedded Systems

- Statische Prozessmenge: Keine weiteren Prozesse kommen hinzu, d.h. alle Prozesse sind gegeben und ablauffähig
- Dynamische Prozessmenge: Während der Ausführung können neue Prozesse hinzukommen, auf die reagiert werden muss
 statisch: alle Möglichen Kombinationen (theoretisch) bekannt dynamisch: unbekannt, was gleichzeitig oder überhaupt geschehen kann
- On-line oder Off-line Scheduling
 - ➤ Off-line (irgendwann vorher): Alle Prozesse auch zukünftige Ankünfte – sind bekannt ⇒ vollständige Information liegt vor
 - ➤ On-line (zur Laufzeit): Lediglich aktuelle Prozesse bekannt ⇒ Entscheidungsfindung auf Grund unvollständiger Information

Off-Line = vor der Laufzeit geplant, dafür müssen alle Informationen bekannt sein On-Line: Planung zur Laufzeit -> jeweils unvollständige Information (z.B. wie lange ein Ausfall dauern wird)



Gestaltungsparameter für Scheduling (2)

- Plattform: Einprozessor/Mehrprozessor
 - Mehrprozessor: Identische oder unterschiedliche Prozessoren
 evtl. Variation der Ausführungsgeschwindigkeiten

Zu jedem Zeitpunkt kann der Zeitplan verändert werden, wenn sich die Prioritäten während der Laufzeit verändern.

- Verdrängung möglich?
- -> Prozesse, die nicht unterbrochen werden können, sind schwer zu planen
- Mit Verdrängung können Schedulingziele besser erreicht werden
- Abhängigkeiten zwischen Prozessen?
 - Reihenfolgebeziehung (partielle Ordnung)
 - Synchronisierte Zuordnung der parallelen Prozesse eines Programms
 - Kommunikationszeiten zu berücksichtigen?
 - Rüstzeiten (Umschaltzeiten) zu berücksichtigen?



Gestaltungsparameter für Scheduling (3)

- Sind Prioritäten zu berücksichtigen?
 - Statische Prioritäten: a-priori (von außen) vorgegeben
 - Dynamische Prioritäten: Bestimmung während der Ausführung
- Sollzeitpunkte zu berücksichtigen? (oft bei Realzeitsystemen)
 - Prozesse müssen zu bestimmten Zeitpunkten beendet werden
- Existieren periodische, regelmäßig wiederkehrende Prozesse?
- Zu erreichendes Ziel, d.h. zu optimierende Zielfunktion, wie z.B.
 - Länge des Ablaufplans
 - Maximale Antwortzeit
 - Mittlere (gewichtete) Antwortzeit
 - Anzahl Prozessoren
 - Durchsatz
 - Prozessorauslastung
 - Maximale Verspätung

(min) Gesamtdauer minimieren

möglichst kurze Wartezeit für alle, z.B. bei (min)

(min) ähnlich max. Antwortzeit, aber Dauer "fairer" verteilt

(min)

Aufgaben / Zeit erledigt (max)

(max)

wenn Verspätung nötig, dann soll diese

Problem: Ziele sind meistens nicht kompatibel, d.h. man muss sich entscheiden



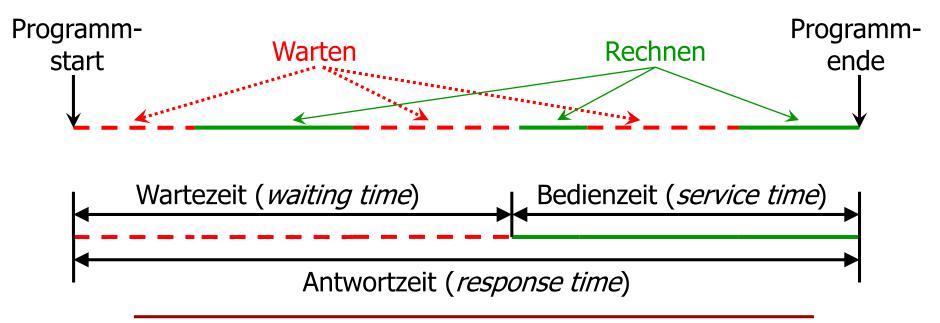
Detaillierte Betrachtung der Schedulingziele

- Ziele für alle Systemarten
 - > Fairness: gerechte Verteilung der Rechenzeiten an Bewerber
 - Policy Enforcement: Transparente Entscheidungskriterien
 - ➤ Balance: Alle Teile des Systems sind ausgelastet
- Ziele bei Stapelverarbeitungssystemen Batch-Systeme
 - Maximiere Durchsatz, d.h. Jobs/Zeiteinheit, z.B. Jobs/Stunde
 - Minimiere Turnaround-Zeit: Zeit zwischen Auftragsstart und Auftragende
- Interaktive Systeme
 - Minimiere die Antwortzeit für Anfragen
 - Proportionalität: Anpassung des Systemverhaltens auf das aktuelle Benutzerprofil
- Echtzeitsysteme
 - Einhaltung von Sollzeitpunkten



3.2 Scheduling in Mehrprogrammsystemen

- Zu erreichende Ziele
 - ➤ Hohe Effizienz ⇒ Hohe Auslastung des Prozessors
 - Geringe Antwortzeit bei interaktiven Prozessen und hoher Durchsatz bei Stapelbetrieb (batch processing)
 - Fairness, d.h. gerechte Verteilung der Prozessorleistung und der Wartezeit unter den Prozessen





Schedulingstrategien in Mehrprogrammsystemen

- Annahmen
 - ➤ Homogenes (symmetrisches) Multiprozessorsystem
 - Dynamische Prozessmenge
 - Keine Abhängigkeiten zwischen Prozessen
 - Dynamisches On-line-Scheduling
 - Keine Sollzeitpunkte
- Strategiealternativen
 - Ohne / mit Verdrängung des Prozesses
 - ➤ Ohne / mit Prioritäten
 - Unabhängig / abhängig von der Bedienzeit



Standardstrategien

Gegeben seien die folgenden fünf Prozesse:

	ab wann kann der Prozess a	rbeiten? Service Time			
Nr.	Ankunft	Bedienzeit	Priorität		
1	0	3	2		
2	2	6	4		
3	4	4	1		
4	6	5	5		
5	8	2	3		

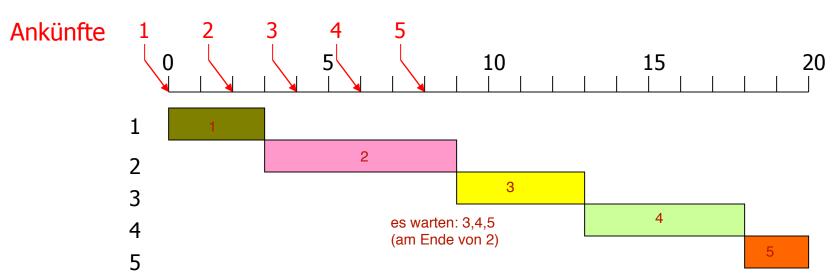


FCFS (First Come First Served) oder FIFO (First In First Out)

Arbeitsweise

- Bearbeitung der Prozesse in der Reihenfolge ihrer Ankunft in der Bereitliste
- Prozessorbesitz bis zum Ende oder zur freiwilligen Aufgabe
- Anmerkung: Entspricht der Alltagserfahrung.

-> Prioriäten werden ignoriert



Vorteile: kein Overhead (optimale Gesamtzeit), transparent

Nachteile: lange Wartezeiten einzelner Prozesse (hier Prozess 5, sehr kurz, muss aber sehr lange warten)



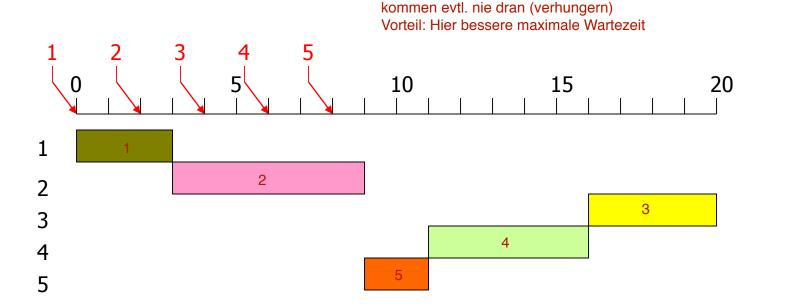
LCFS (Last Come First Served)

Arbeitsweise

- Bearbeitung der Prozesse in der umgekehrten Reihenfolge ihrer Ankunft in der Bereitliste
- > Prozessorbesitz bis zum Ende oder zur freiwilligen Aufgabe

Nachteile: "unfair", Prozesse unten im Stapel warten lange oder

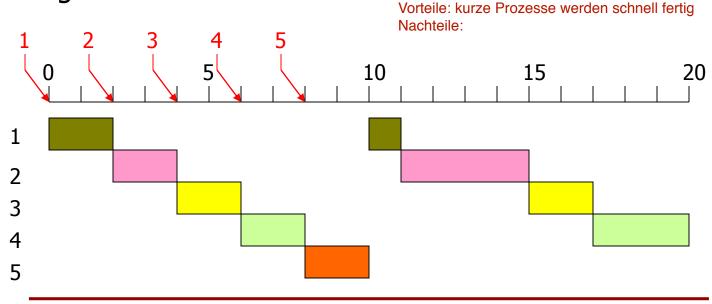
> Anmerkung: In dieser reinen Form selten benutzt





LCFS-PR (Last Come First Served - Preemptive Resume)

- Neuankömmling in Bereitliste verdrängt den rechnenden Prozess, verdrängter Prozess wird hinten in die Warteschlange eingereiht
- Ziel ist die Bevorzugung kurzer Prozesse.
 - Kurzer Prozess hat die Chance, schnell (vor der nächsten Ankunft) fertig zu werden
 - Ein langer Prozess wird u.U. mehrfach verdrängt
- Nach dem Eintreffen aller Prozesse wird die Warteschlange nach FIFO abgearbeitet

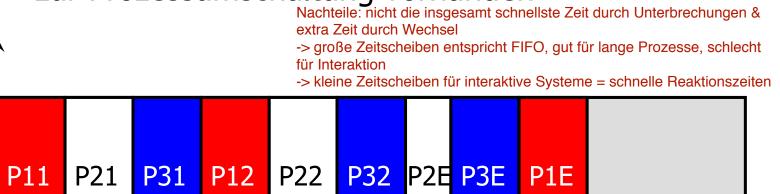




Zeitscheibenbetrieb (Time Sharing Mode)

Round Robin

- Abwicklung taktgesteuert und nebenläufig
 - > Jeder Prozess erhält im festen Takt ein Zeitfenster zugeteilt
 - ➤ Ist er am Ende des Zeitfensters nicht fertig, dann wird er unterbrochen und in einer Warteschlange hinten angestellt
 - Änderung der Taktung durch Prioritäten, Warten auf Fertigstellung eines E/A-Auftrags, ...
- Voraussetzung: Prozesse unterbrechbar und Mechanismen zur Prozessumschaltung vorhanden



Zeit

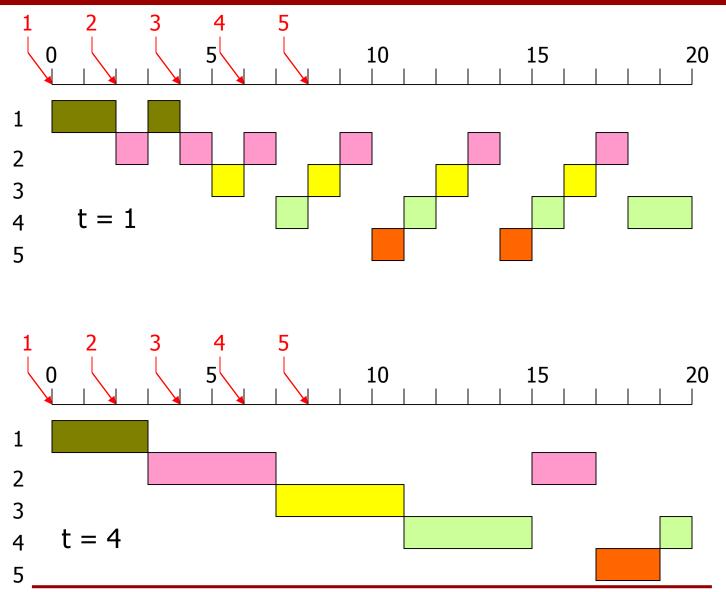


Round Robin: Zeitscheibenlänge

- Ziel des Verfahrens ist die gleichmäßige Verteilung der Prozessorkapazität und der Wartezeit auf die Prozesse
- Wahl der Zeitscheibenlänge t ist Optimierungsproblem
 - > Für großes t nähert sich RR der Reihenfolgestrategie FCFS
 - Für kleines t schlägt der Aufwand für das häufige Umschalten negativ zu Buche
- Üblich sind Zeiten im msec-Bereich



RR Round Robin



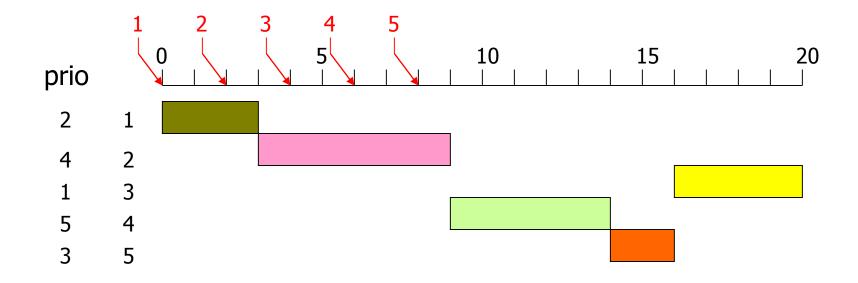


PRIO-NP (Priorities – non preemptive)

- Neuankömmlinge werden nach ihrer Priorität in die Bereitliste eingeordnet
 - > Prozessorbesitz bis zum Ende oder zur freiwilligen Aufgabe

PrioQueue ohne Verdrängung von laufenden Prozessen

Problem: Prioritäten müssen definiert werden im OS: Systemprozesse > User Prozesse

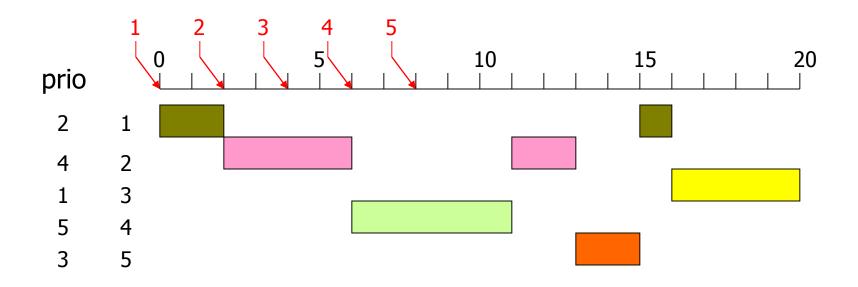




PRIO-P (Priorities – Preemptive)

- Wie PRIO-NP, jedoch findet Verdrängungsprüfung statt
 - ⇒der rechnende Prozess wird verdrängt, wenn er eine geringere Priorität hat als der Neuankömmling

PrioQueue mit Verdrängung des laufenden Prozesses





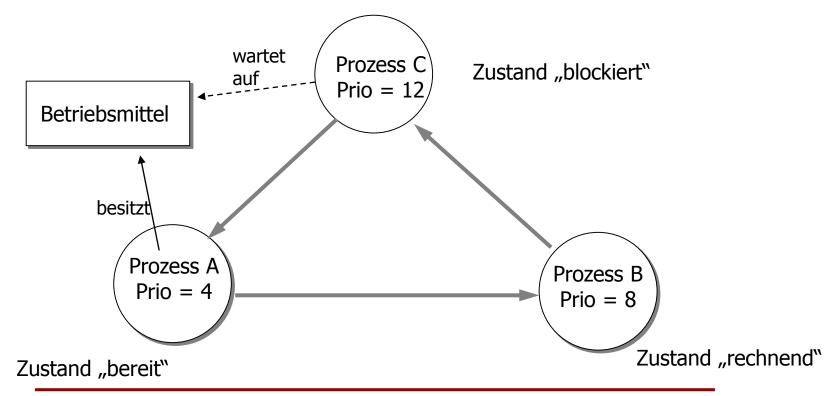
Prioritätsinvertierung

- Prozess C wird "verhungern", obwohl er der dringlichste ist
 - B blockiert die CPU, A kommt nicht dran und kann das Betriebsmittel nicht freigeben, Grund: Entziehen von Betriebsmittel ist gefährlich, z.B.
 - ⇒ C bleibt auf unbestimmte Zeit blockiert

können korrupte Daten oder Inkonsistenzen in Datenbanken entstehen

-> OS entzieht üblicherweise keine Betriebsmittel

- Lösung?
 - ➤ A bekommt Priorität von C, solange A das Betriebsmittel besitzt

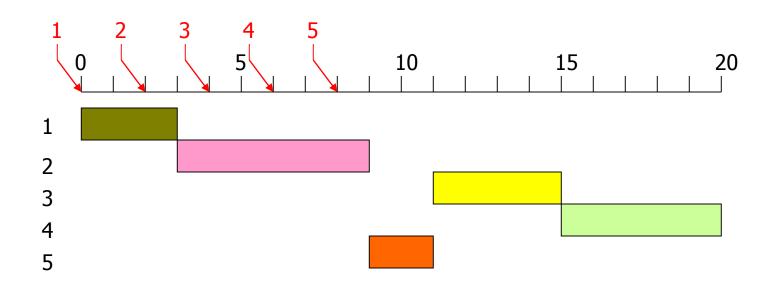




SJN (Shortest Job Next)

- Prozess mit kürzester Bedienzeit wird als nächster bis zum Ende oder zur freiwilligen Aufgabe bearbeitet.
 - Wie PRIO-NP mit Bedienzeit als Prioritätskriterium
 - Bevorzugt kurze Prozesse

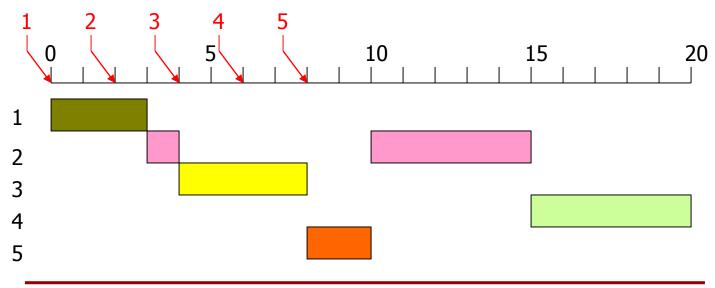
praktisch kaum relevant





SRTN (Shortest Remaining Time Next)

- Prozess mit kürzester Restbedienzeit wird als nächster bearbeitet
 - Rechnender Prozess kann verdrängt werden
 - Nachteil: Schätzung der Bedienzeit stammt vom Benutzer
 - ⇒ Längere Prozesse können "verhungern", wenn immer kürzere vorhanden sind

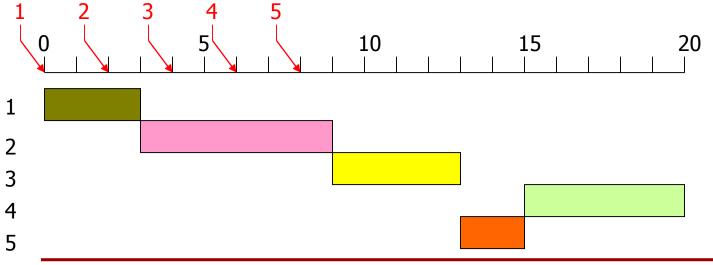




HRRN (Highest Response Ratio Next)

- Arbeitsweise
 - > Response Ratio rr ist definiert als rr := Wartezeit + Bedienzeit

 Bedienzeit
 - > rr wird dynamisch berechnet und als Priorität verwendet
 - Prozess mit größtem rr -Wert wird als nächster ausgewählt.
 - Strategie ist nicht verdrängend
 - Wie bei SJN: Bevorzugung kurzer Prozesse, aber lange Prozesse können durch Warten "Punkte sammeln".





3.3 Multilevel-Scheduling

- Kombination unterschiedlicher Scheduling-Verfahren
 - ➤ Durch die Verknüpfung können Schedulingstrategien besser auf die Betriebsform (Dialogbetrieb, Stapelbetrieb, ...) abgestimmt werden
- Einfachste Realisierung
 - Unterteilung der Liste bereiter Prozesse in mehrere Sublisten
 - > Jede Liste kann anhand verschiedener Strategien verwaltet werden
 - Aufträge werden je nach gewünschter Betriebsform in die entsprechende Liste einsortiert
 - ➤ Mit zusätzlichem Auswahlverfahren wird bestimmt, welcher Prozess aus welcher Subliste zur Ausführung gebracht wird
 - Prioritätsvergabe pro Liste führt dazu, dass z.B. zeitkritsche Prozesse bevorzugt behandelt werden

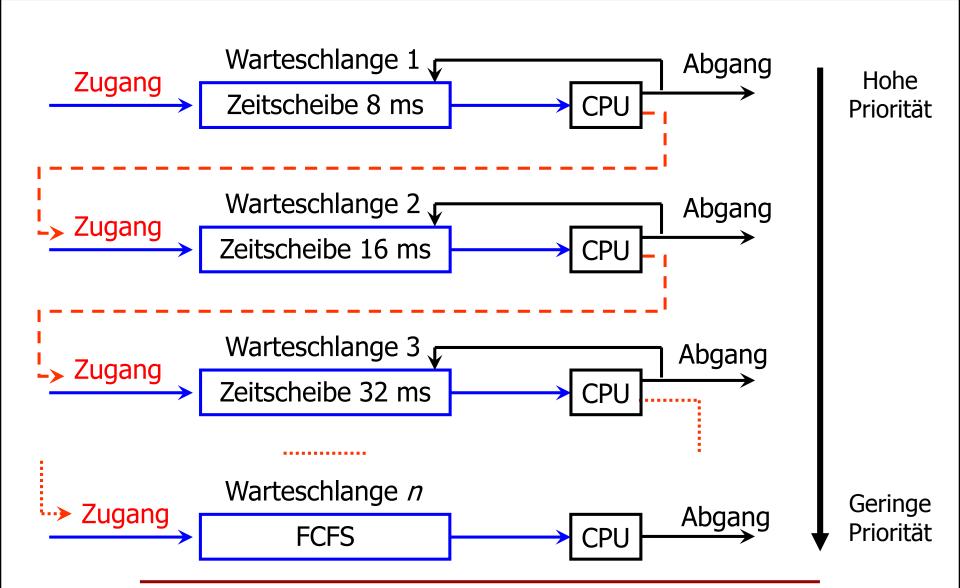


Feedback-Scheduling

- Grundidee ist die Berücksichtigung von
 - "Warte"-Historie eines bereiten Prozesses
 - Periodizität bei Prozessausführung
 - ⇒Schedulingkriterien werden an den aktuellen Systemzustand angepasst
 - ⇒Beispiel: Aging bevorzugt unverhältnismäßig lang (bzgl. ihrer Ausführungszeit) wartende Prozesse
- Multilevel-Feedback-Scheduling
 - Ausführungszeit und Ausführungsverhalten der Prozesse ist nicht im Voraus bekannt
 - Anpassung an Ausführungsverhalten: Modifikation der Zeitscheibenlänge
 - Anpassung an Ausführungszeit: Stufenweise Prioritätenreduktion



Multilevel-Feedback-Scheduling





Multilevel-Feedback-Scheduling (2)

- Grundlage: RR-Verfahren mit Bereit-Liste, welche in mehrere Teillisten untergliedert wird
 - Unterschiedliche Länge der Zeitscheiben/Liste
 - Unterschiedliche Prioritäten/Liste
 - Unterste Warteschlange funktioniert nach dem FCFS-Prinzip
- Vorgehensweise
 - Verdrängte Prozesse (benötigen also mehr Zeit) kommen in eine Bereit-Liste mit längerer Zeitscheibe/geringerer Priorität
 - Prozesse, welche blockierende Operationen aufrufen oder den Prozessor freiwillig abgeben, verbleiben in der Warteschlange
 Bevorzugung E/A-intensiver Anwendungen
 - Zusätzliche Feedback-Mechanismen ermöglichen eine Hochstufung (kürzere Zeitscheibe/höhere Priorität)



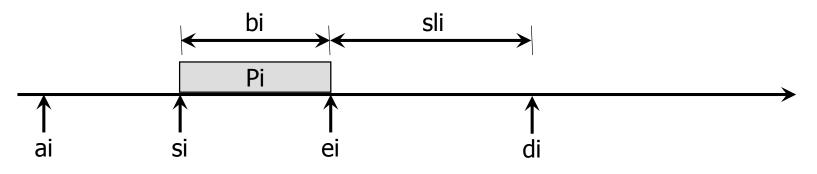
3.4 Scheduling mit Sollzeitpunkten

- Sollzeitpunkte treten primär in Realzeitsystemen wie Steuerrechnern für Fertigungsstraßen, Motorsteuerung ... auf
 - Vollständige Bearbeitung eines Prozesses zu einem bestimmten, apriori festgelegten Sollzeitpunkt (deadline), z.B. Auswertung von Messgrößen innerhalb knapper Zeitschranken
 - ⇒ Einhaltung der Sollzeitpunkte teilweise kritisch für die Funktion des Gesamtsystems
- Können Verletzungen der Sollzeitpunkte toleriert werden?
 - Strikte Echtzeitsysteme (Hard real-time systems)
 - Verletzung wegen Systemausfall untolerierbar (z.B. Airbag, ABS, Öffnung von Ventilen beim Überdruck, ...)
 - ⇒Oft Einsatz von Off-Line-Algorithmen notwendig
 - Schwache Echtzeitsysteme (Soft real-time systems)
 - Verletzung zwar tolerierbar, führt aber zu Qualitätsverlusten (z.B. Internet-Telefonie, Videoübertragung im Internet)



Wichtige Zeitpunkte bei Realzeitprozessen

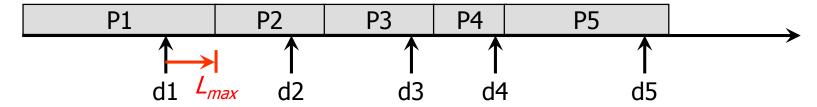
- Voraussetzung
 - Früheste Anfangszeit und späteste Endzeit sind a-priori vorgegeben und bekannt
- Wichtige Zeitpunkte für einen Prozess Pi:
 - > Frühester Startzeitpunkt ai
 - Tatsächlicher Startzeitpunkt si
 - Tatsächlicher Endzeitpunkt ei
 - Spätester Endzeitpunkt di (Sollzeitpunkt, deadline)
 - Bedienzeit (service time) bi = ei-si
 - > Spielraum (*slack-time, laxity*) sli = di-si





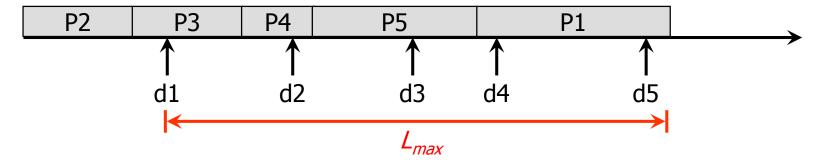
Verspätungen

- Überschreitung der Sollzeit (ei > di): Verspätung (lateness) L=ei-di
- Mögliche Zielfunktionen bei tolerierbaren Verspätungen (Soft-RTS)
 - 1. Minimierung der maximalen Verspätung *Lmax*



Ergebnis: Maximale Verspätung minimiert, aber alle Deadlines verpasst

2. Einhaltung von möglichst vielen Deadlines, ohne Berücksichtigung der maximalen Verspätung





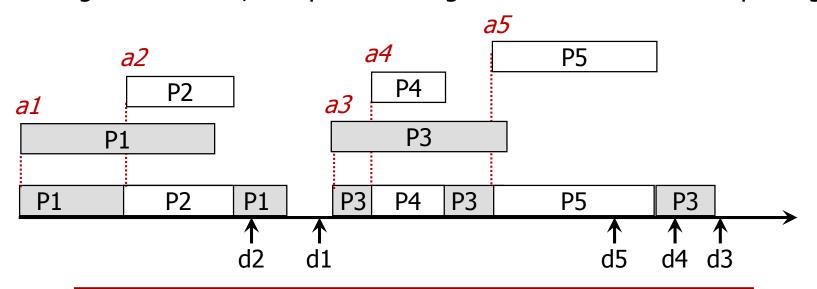
Minimierung der maximalen Verspätung

- Bei Einprozessorsystemen ohne Verdrängung und ohne Abhängigkeiten zwischen Prozessen
 - ⇒Scheduling durch Permutation der Prozesse
- Theorem EDD (Earliest Due Date), Jacksons Regel
 - > Relaxation: Alle Prozesse können zu jedem Zeitpunkt beginnen
 - ➤ Jeder Ablaufplan, in dem die Prozesse nach nicht fallenden Sollzeitpunkten geordnet ausgeführt werden, ist optimal bezüglich *Lmax*
 - Lediglich Sortiervorgang mit O(nlog n) notwendig
- Praxis
 - Durch die Einführung von unterschiedlichen Startzeitpunkten ($\exists i,j: a_i \neq a_j$) wird das Problem NP-schwer, d.h. es ist nicht in polynomialer Zeit optimal lösbar



Minimierung der maximalen Verspätung (2)

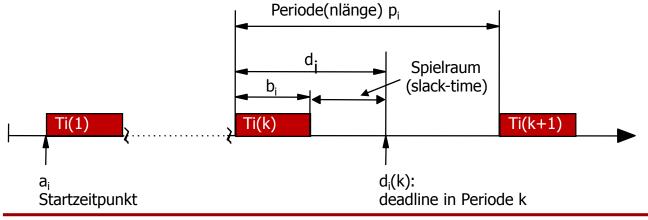
- Voraussetzung
 - Vorgegebene Startzeitpunkte
 - Verdrängung möglich
- Theorem EDF (*Earliest Deadline First*)
 - Jeder Ablaufplan, in dem zu jedem Zeitpunkt der Prozess mit dem frühesten Sollzeitpunkt unter allen ablaufbereiten Prozessen zugeordnet wird, ist optimal bezüglich der maximalen Verspätung





Periodische Prozesse

- Periodische Aufgaben mit Deadlines kommen zu bestimmten Zeitpunkten immer wieder
 - ⇒ Jeder Prozess ist gekennzeichnet durch **Periode** bzw. die dazu reziproke **Rate**
- Ist die Schedulingaufgabe lösbar (schedulability test, feasibility test)?
 - Für jeden periodischen Prozess muss gelten: $0 < b_i \le d_i \le p_i$
 - ► Bei mehreren periodischen Prozessen muss gelten: $\sum_{i} \frac{b_{i}}{p_{i}} \le 1$





Periodische Prozesse

- Ratenmonotones Verfahren (rate monotonic scheduling)
 - Statische Priorität für jeden Prozess, die umgekehrt proportional ist zu der Periode
 - ⇒ Prozess mit der kleinsten Periode hat die höchste Priorität
- Voraussetzung: Unabhängige Prozesse und Sollzeitpunkte fallen mit den Perioden zusammen
- Satz: Eine Menge von n periodischen Prozessen kann durch ein ratenmonotones Verfahren eingeplant werden, wenn folgendes gilt (hinreichende Bedingung):

$$\sum_{i=1}^n \frac{b_i}{p_i} \leq n \left(2^{\frac{1}{n}} - 1 \right)$$

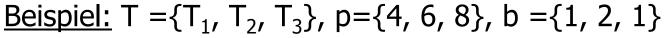
- Links: benötigte Prozessorleistung
- Rechts: obere Schranke für einen zulässigen Schedule
- Bei großen n ⇒ CPU-Auslastung höchstens In 2 ≈ 69,3 %

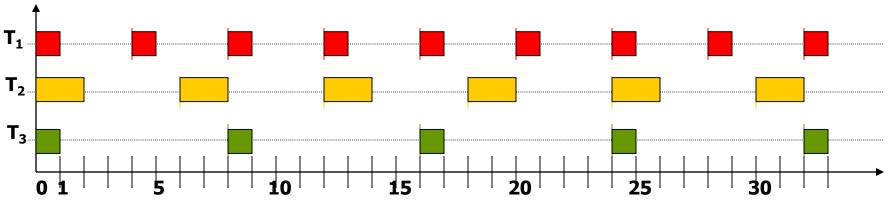


Rate Monotonic Scheduling

Annahmen

- 1. Prozess T_i ist periodisch mit Periodenlänge p_i
- 2. Deadline ist $d_i = p_i$
- 3. T_i ist unmittelbar nach p_i erneut bereit
- 4. T_i hat eine konstante Bedienzeit b_i ($\leq p_i$)
- 5. Je kleiner die Periode, desto höher die Priorität





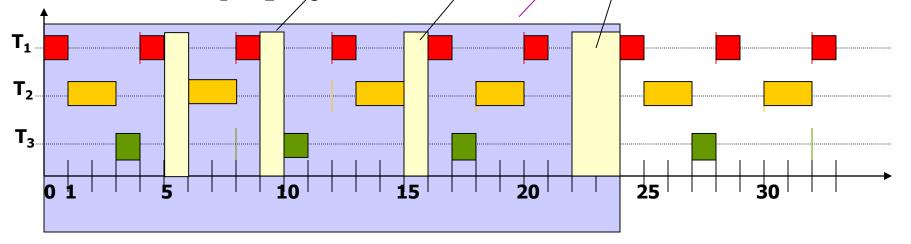
Wie sieht die Einplanung auf einem Prozessor aus?



Rate Monotonic Scheduling (RMS)

- Annahmen
 - 1. Prozess Ti ist periodisch mit Periodenlänge pi
 - 2. Deadline ist di = pi
 - 3. Ti ist unmittelbar nach pi erneut bereit
 - 4. Ti hat eine konstante Bédienzeit þí (<= pi/)
 - 5. Je kleiner die Periode, desto höher die Priorität

Beispiel: $T = \{T_1, T_2, T_3\}, p = \{4, 6, 8\}, b \neq \{1, 2, 1\}$



Leerzeiten

Hyperperiode



Ergebnis des RMS-Beispiels

Die allgemeine **notwendige Bedingung** ist erfüllt:

$$(1/4 + 2/6 + 1/8) = 17/24 <= 1$$

Auch das hinreichende RMS-Kriterium ist erfüllt:

$$(1/4 + 2/6 + 1/8) = 17/24 = 0,7083 < 3 (2^{1/3}-1) \approx 78 \%$$
.



3.5 Fallbeispiel: UNIX-Scheduling

- UNIX/Linux-Scheduling basiert auf Multilevel-Feedback-Scheduling
 - Statische und dynamische Prioritäten zur Prozessauswahl
 - Verwaltung der lauffähigen Prozesse in einer Liste (runqueue)
- Scheduling-Verfahren (policies)
 - > SCHED_OTHER: basiert auf PRIO-P, für "normale" Prozesse
 - Statische Priorität = 20, dynamische Priorität (nice): [-20 19]
 - Verdrängung durch Prozesse mit höherer statischer Priorität
 - Die nicht verbrauchte Zeitscheibe bleibt als "Gutachten" erhalten
 - SCHED_FIFO: FCFS, für "Echtzeitprozesse" (Real-Time FIFO)
 - Statische Priorität: 1-99, bei gleicher Priorität Wahl des ersten Prozesses
 - Verdrängung durch Prozesse mit höherer statischer Priorität
 - SCHED_RR: Round-Robin, für "Echtzeitprozesse" (Real-Time RR)
 - Statische Priorität: 1-99, bei gleicher statischer Priorität ⇒ FIFO
 - Nach Ablauf der Zeitscheibe ⇒ Einordnung ans Ende der runqueue
 - Verdrängung durch Prozesse mit höherer statischer Priorität



22

21

20

Multilevel-Scheduling von Prozessen

Statische Priorität Abarbeitungsreihenfolge 99 SCHED_RR oder 98 SCHED_FIFO ... C D FIFO

SCHED OTHER

E

 \mathbf{F}

G

PRIO



Funktionsweise des Schedulers

- Scheduling-Algorithmus in Linux
 - ➤ Entferne alle Prozesse aus der Wartschlange runqueue, deren Zustand nicht TASK_RUNNING ist, d.h. die nicht ablaufbereit sind
 - Bewerte jeden lauffähigen Prozess aus der runqueue und wähle den Prozess mit der höchsten Bewertung
 - Wenn alle Zeitkonten (Quantum) der lauffähigen Prozesse (blockierte werden nicht berücksichtigt) abgelaufen sind, dann berechne die Zeitkonten aller Prozesse neu
 - Quantum: Bestimmte Anzahl sog. Uhrticks, üblicherweise 20, wobei ein Uhrtick etwa 10ms beträgt
 - Bestimme den auszuführenden Prozess und rufe Dispatcher auf
- CPU wird entzogen, wenn
 - Quantum vollständig verbraucht (Quantum=0)
 - Thread blockiert wegen E/A
 - Thread höherer Priorität ist ablaufbereit



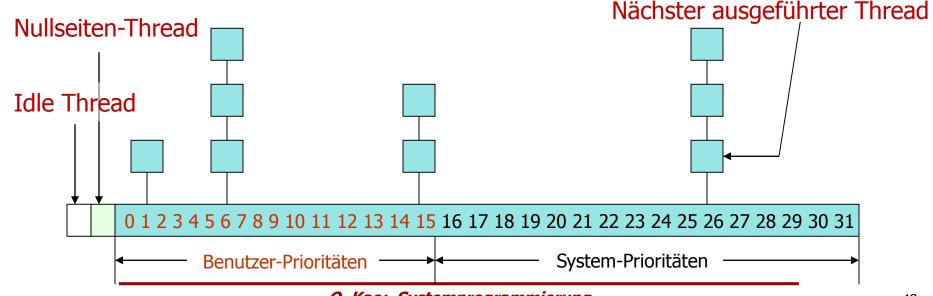
Prozessbewertung

- Bewertung eines Prozesses durch die Funktion goodness(…)
 - 1. Rückgabe –1: Freiwillige Abgabe der CPU
 - 2. Rückgabe 0: Quantum aufgebraucht
 - 3. Rückgabe [1-1000]: Normaler Prozess
 - 4. Rückgabe > 1000: Echtzeitprozess
 - ⇒ Je größer der Rückgabewert, desto besser ist die Bewertung
- Berechnung der Funktion goodness() im Fall 3 und 4
 - Bei normalen Prozessen (Fall 3)
 - Allgemein: Güte = quantum + priorität
 - Gleicher Prozess hat noch Zeit übrig:
 Güte = quantum + priorität + 1
 - Gleicher Adressraum wie aktueller Prozess:
 Güte = quantum + priorität + 1
 - ➤ Bei Echtzeit-Prozessen (Fall 4): Güte = 1000 + Priorität
- Neuberechnung: Quantum_neu = Quantum_alt/2+Basispriorität



Windows: Arbeitsweise des Scheduling-Algorithmus

- Verwaltung der Prioritätsliste mit 32 Prioritäten
 - > Jeder Eintrag enthält Liste mit allen wartenden Threads der gleichen Priorität
 - Durchlaufen der Liste von Priorität 31 bis Priorität 0
 - ▶ Bei nichtleerem Eintrag ⇒ führe die Prozesse nach Round-Robin aus
- Spezielle Threads
 - > Null Thread: läuft im Hintergrund, überschreibt Speicherseiten mit Nullen
 - Idle Thread: Läuft, wenn keine anderen Threads inkl. Null Thread aktiv





Zeitscheibenlänge

- Zeitscheibenlängen
 - > Standardeinstellung: 20ms, Einzelprozessor-Server: 120ms
 - Multiprozessor-Systemen: abhängig von Taktfrequenz
 - Einstellungen können um Faktor 2, 4 oder 6 erhöht werden
 - Kürzere Zeitscheiben bevorzugen interaktive Benutzer
 - Längere Zeitscheiben erfordern weniger Kontextwechsel und sind effizienter
- Verringerung der Priorität
 - Verbraucht ein Thread seine gesamte n\u00e4chste Zeitscheibe, so wird seine Priorit\u00e4t um eine Einheit verringert, solange die aktuelle Priorit\u00e4t h\u00f6her ist als seine Basispriorit\u00e4t (Variante von Aging)



Scheduling in Windows

- Kombination aus Prozess- und Threadpriorität ergibt 32 Werte [0, 31]
 - ightharpoonup Systemprioritäten 16..31 \Rightarrow Zuweisung durch Administrator
 - ➤ Benutzerprioritäten 0..15 (Änderung mit API SetThreadPriority)

		Win32-Prozessklassen-Prioritäten					
		Echtzeit	Hoch	Über normal	Normal	Unter normal	Idle
	Zeitkritisch	31	15	15	15	15	15
	Höchste	26	15	12	10	8	6
Win32-	Über normal	25	14	11	9	7	5
Thread-	Normal	24	13	10	8	6	4
Prioritäten	Unter normal	23	12	9	7	5	3
	Niedrigste	22	11	8	6	4	2
	Idle	16	1	1	1	1	1